Classification de textes

Le but de ce TP/Projet est de travailler sur la classification de sentiments à partir du dataset IMDb (vu en TP3) et la détection de spam sur un nouveau dataset. Vous allez implémenter des modèles de classification avec PyTorch en utilisant un simple MLP. Enfin, vous allez travailler sur la partie non étiquetée du dataset (unsupervised) avec des méthodes d'apprentissage non supervisées.

Partie 1 : Analyse et complétion du modèle MLP

Implémentation d'un réseau de neurones avec PyTorch et adaptation de la fonction de perte et les hyper-paramètres.

En analysant le code dans le fichier *mlp_26.py* Répondez aux questions suivantes (ajouter les réponses dans votre rapport)) :

1. Comment les données sont chargées dans le code ?
2. Les données sont-elles chargées en une fois ou en batch ? Pourquoi le faire aussi pour Test ?
3. Combien de couches cachées sont utilisées dans ce modèles ?
4. Donnez le nombre de neurones d'entrée et de sortie pour les différentes couches.
5. Qu'elle loss fonction est utilisée dans ce modèle ?
6. Complétez et tester le code
7. Adaptez les hyper-paramètres de votre modèles. Comparez les résultats avec et sans cette adaptation.
8. Ajouter une couche de *dropout* (couche d'oublie) pour éviter le sur-apprentissage? quel impact ?
9. Changer la fonction objective en la remplaçant par une de votre choix (**L'Entropie Croisée Binaire Pondérée**).
10. Comparez les résultats avec et sans ce changement.

Partie 2 : Apprentissage semi-supervisé

Implémenter une approche semi-supervisée qui combine une approche supervisée (de votre choix) et une approche non supervisé (de votre choix). Cette dernière permet d'annoter le dataset unsupervised de IMDb disponible sur Huggingface.

1. Expliquez votre approche (comment est faite la combinaison ?)
2. Les clusters correspondent-ils réellement à des sentiments ?
3. Quels sont les risques de cette approche ?
4. Les performances sont-elles fiables ? Comparer avec le dataset IMDb annoté.

Partie 3 : Comparaison de plusieurs modèles de classification

1. Implémenter et comparer plusieurs modèles de machine learning sur IMDb (voir TP3) et sur le dataset spam (les données du fichier spam.csv).
2. Comment sont découpées les données en train et test pour le datasets spam ?
3. Quel modèle donne les meilleurs résultats pour chaque dataset ?
4. Est-ce que votre évaluation est significative ? (le score change sur pluesieurs évaluations ?)

Partie 4 : Mise en production

Implémenter une interface Client/Serveur simple pour la mise en production votre modèle (un modèle d'analyse de sentiment ou de détection de spams aux choix). Utiliser Flask pour la partie server Web et HTML/CSS/Javascript pour la partie Client.

1. L'API doit permettre de choisir entre au moins deux modèles parmi ceux étudiés précédemment (par exemple : MLP, SVM, Random Forest, etc.). Le modèle utilisé devra être spécifié dans la requête.
2. Proposer une explication simple de la prédiction (ex. mots ayant influencé la décision (via TF-IDF)
3. Dans le rapport, montrez le test de 3 exemples bien classés et 2 mal classés

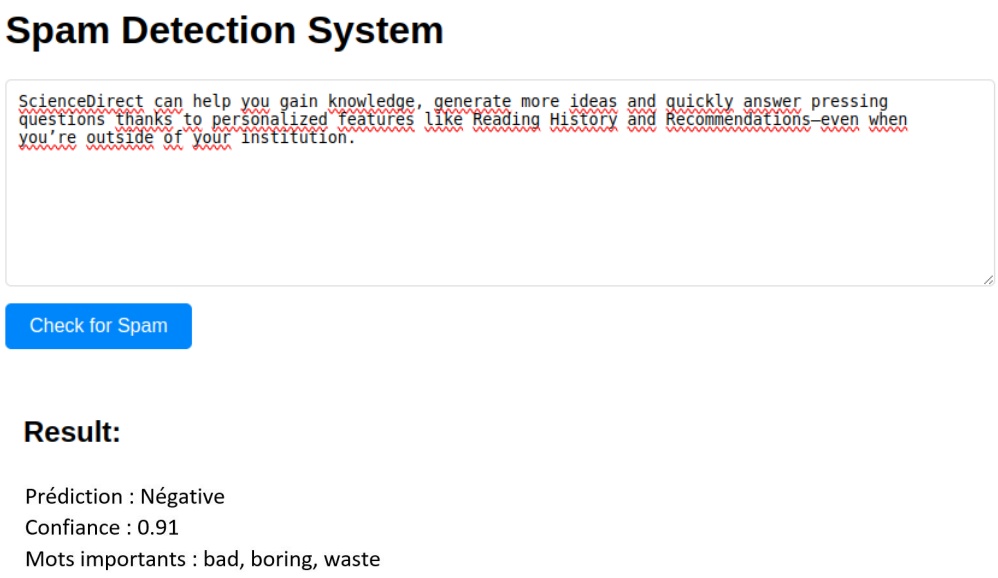

FIGURE 1 – Systeme de détection de spam avec flask.

Modalités de réalisation

1. Projet à réaliser en binôme ou trinôme (maximum).
2. L'inscription du binôme/trinôme se fera lors du TP4.
3. Langage de programmation : Python
4. La notation sera basée sur l'avance en TP4 (4 pts) ; sur la qualité des modèles et la façon dont ils sont implantés (10 pts) et sur le mini-rapport (6 pts).
5. Le mini-rapport doit valoriser votre travail de façon synthétique (5 pages max). Ajoutez un tableaux comparant les différents modèles testés pour chaque dataset.
6. Précisez l'usage que vous avez fait des IAs génératives de type ChatGPT.
7. Le code et le rapport sont à déposer sur plubel avant le 01/05 à 23h59.